Decisiones técnicas clave

Entorno modular, recompensa VWAP y demostración completa de entrenamiento

OBJETIVO

Construir una base estable y extensible que ejecute episodios completos, publique un contrato común para el equipo y demuestre el ciclo **experiencia - aprendizaje - evaluación** con datos de REP.

ARQUITECTURA Y CONTRATO

- **BestExecutionEnv** se extrajo del notebook a `src/environment` para evitar duplicación.
- El entorno recibe **EnvironmentConfig** y una **RewardStrategy**: composición frente a lógica acoplada.
- `reset()` devuelve la observación inicial; `step()` devuelve estado, reward, done e info. El estado terminal es `None`.
- La configuración es tipada e inmutable; valida rangos de duración, `look_back`, CARE y semilla.

EPISODIO, ESTADO Y ACCIONES

- Un RNG local (`default_rng`) selecciona día, inicio, duración y tamaño CARE sin consumir aleatoriedad al detectar features.
- Estado base: fraccion de **tiempo restante** y de **volumen restante**, normalizadas y en `float32`.
- Acción 0 espera; acción 1 compra un título al mejor ask. Un registro común mantiene precios, volúmenes, rewards y VWAP alineados.
- El episodio termina por tiempo o por CARE completada; la ejecución unitaria evita sobrepasar el volumen objetivo.

MERCADO Y VWAP

- Precio de mercado aproximado por el **mid**: `(ask1 + bid1) / 2`.
- Volumen por bin: diferencia de `cumvol`, con control de monotonía y volumen total positivo.
- El VWAP alinea el mid del bin anterior con el volumen observado en el bin siguiente y evita la alineación implícita de pandas.

RECOMPENSA Y FINALIZACION

- Reward inmediato VWAP: `(episode_vwap - execution_price) / episode_vwap`; esperar aporta cero.
- Penalización terminal: fracción CARE pendiente en `[-1, 0]`. Es cero al completar y comparable entre tamaños de orden.
- La lógica de reward vive fuera del entorno mediante **RewardContext** y una interfaz abstracta.

EVIDENCIA DE ACEPTACIÓN

10 tests
Forma, parada, CARE, reproducibilidad, episodio completo y penalización terminal.

REP real
Notebook ejecutado con replay buffer, aprendizaje, red objetivo y evaluación sobre test.

Seed 42
Misma configuración y datos producen la misma secuencia de episodios y acciones.

ENTRENAMIENTO DDQN: DECISIONES DE DEMOSTRACIÓN

- **Replay:** 256 pasos de calentamiento, buffer 2.000 y batch 32 para aportar diversidad con coste moderado.
- **Actualización:** aprender cada 16 pasos y sincronizar la red objetivo cada 128 (ocho aprendizajes por objetivo).
- **Exploración y valor:** epsilon lineal de 1,00 a 0,05; gamma 0,99; Adam con alpha 0,001; dos capas de 32 neuronas.
- **Alcance:** 10 episodios prueban el pipeline de extremo a extremo; no constituyen evidencia de convergencia ni una calibración final.

ALCANCE CONSCIENTE

El ejercicio cierra la infraestructura y demuestra funcionamiento. La calibración TWAP, la exploración adaptativa, los checkpoints y la evidencia de convergencia pertenecen a los siguientes bloques del proyecto.